

BLM3810 Biyoenformatiğe Giriş

Gen İfadesi Veri Setleri, Gen Analizleri ve Makine Öğrenmesi ile Sınıflandırma Projesi

Grup Yapısı	Proje iki kişilik gruplar halinde hazırlanacaktır.
Veri Seti Bildirimi	18 Mayıs 2026, 23:59 tarihine kadar form üzerinden yapılmalıdır.
Proje Son Teslim	04 Haziran 2026, 23:59 - online.yildiz.edu.tr
Sunumlar	05 Haziran 2026 ders gününde başlayacaktır. Grup sunum saatleri ayrıca ilan edilecektir.
Teslim Formatı	İstediğiniz dilde yazdığınız kodlar, rapor ve sunumunuzun bulunduğu zip klasörü. Rapor PDF formatında; kodlar, görseller ve sunum dosyası ile birlikte teslim edilmelidir.

Önemli: Seçilen veri setleri gruplar arasında farklı olmalıdır. Bu nedenle formu doldurmadan önce daha önce seçilmiş veri setlerini kontrol ediniz.

1. Projenin Amacı

Bu projenin amacı, gen ifadesi veri setleri üzerinde temel biyoinformatik analizleri uygulamak ve elde edilen biyolojik bulguları makine öğrenmesi yöntemleriyle sınıflandırma problemine dönüştürmektir. Proje iki aşamadan oluşmaktadır:

- 1. aşamada veri seti seçimi, ön işleme, diferansiyel gen ifadesi analizi, survival analizi, WGCNA ve GO enrichment analizleri yapılacaktır.
- 2. aşamada seçilen gruplar(sınıflar) için farklı özellik seçimi/çıkarımı stratejileri kullanılarak makine öğrenmesi ile sınıflandırma gerçekleştirilecektir.

2. Proje 1. Aşaması: Veri Seti ve Gen Analizleri

2.1. Veri Seti Seçimi

- Veri seti, seçilen hastalık için NCBI GEO DataSets sayfasından bulunabilir: <https://www.ncbi.nlm.nih.gov/geo/>
- Sınıflandırma problemi kurulacağı için veri setinde hasta-sağlıklı, tümör-normal, moleküler alt tip gibi en az iki karşılaştırılabilir sınıf bulunmalıdır.
- Kanser evresi (stage) doğrudan sınıflandırma etiketi olarak seçilmemelidir.
- Survival analizi yapılacağı için veri setinin metadata bilgisinde time-event bilgisi bulunmalıdır.
- Grup bilgisi ve seçilen veri seti bilgileri, belirtilen form üzerinden son tarihe kadar girilmelidir.

2.2. Veri Seti Ön İşleme

- Veri seti raw formatta indirilmeli ve derste paylaşılan örnek koda benzer şekilde işlenmelidir.
- Gen sembolleri ile anotasyon yapılmalıdır.
- Normalizasyon adımları uygulanmalı ve normalizasyon öncesi/sonrası uygun grafiklerle gösterilmelidir.
- Özellik seçim adımı olarak highly variable genes (HVG) seçilmeli; örneğin Top-3000 gen kullanılabilir.
- Örnek koda yer alan çıktılar ve görseller benzer şekilde rapora eklenmelidir.

2.3. Differential Gene Expression (DGE) Analizi

- Seçilen sınıflara göre up-regulated ve down-regulated genler belirlenmelidir.
- Seçilen genlerin adjusted p-value < 0.05 koşulunu sağladığı kontrol edilmelidir.
- Genler Log Fold Change (LogFC) değerlerine göre sıralanmalıdır.
- Sonuçların dağılımına göre uygun bir LogFC threshold değeri belirlenebilir. Genel olarak $|\text{LogFC}| > 1$ tercih edilir; ancak veri setine göre daha esnek bir eşik kullanılabilir.
- Top-5 gen için boxplot ve violin plot oluşturulmalıdır.

- Boxplot grafiklerine istatistiksel test sonucu eklenmelidir.

2.4. Survival Analizi ve Cox Modeli

- LogFC değerlerine göre sıralanmış up-regulated ve down-regulated genlerden Top-5 aday seçilerek survival analizi uygulanmalıdır.
- Eğer Top-5 genlerin tamamı yalnızca up-regulated veya yalnızca down-regulated ise, karşı gruptan da örnek gen eklenmelidir.
- Kaplan-Meier survival grafikleri oluşturulmalı ve sonuçları yorumlanmalıdır.
- Metadata içinde bulunan grup, yaş, cinsiyet, sigara/alkol kullanımı gibi uygun klinik değişkenler kullanılarak Cox regresyon modeli kurulmalıdır.
- Cox modeli sonuçları Forest plot ile gösterilmeli ve hazard ratio değerleri yorumlanmalıdır.

2.5. WGCNA Analizi

- Gene co-expression network modülleri oluşturulmalıdır.
- Soft-threshold power parametresi seçilmeli ve seçim süreci grafiklerle gösterilmelidir.
- Örnek kodda her modül için bir hub gen seçilmiştir. Bu projede her modül için birden fazla hub gen belirlenmelidir.
- Cytoscape uygulaması kullanılarak seçilen örnek bir modülün alt kümesi için network grafiği oluşturulmalıdır. Çok yoğun networklerde en yüksek bağlantılı genler veya yüksek TOM değerine sahip kenarlar seçilebilir.

2.6. GO Enrichment Analizi

- Seçilen örnek bir WGCNA modülü için GO enrichment analizi uygulanmalıdır.
- Sonuçlar bar plot ve dot plot ile görselleştirilmelidir.
- En anlamlı biyolojik süreçler kısa bir paragrafla yorumlanmalıdır.

3. Proje 2. Aşaması: Makine Öğrenmesi ile Sınıflandırma

İlk aşamada seçilen gruplar için makine öğrenmesi yöntemleri kullanılarak sınıflandırma yapılacaktır. Bu aşamada farklı özellik seçimi/çıkarımı stratejilerinin model başarısı üzerindeki etkisi karşılaştırılmalıdır.

3.1. Feature Selection / Feature Extraction Setup'ları

Setup	Kullanılacak Özellikler	Beklenen Karşılaştırma
Setup-1	Gen analizlerinde belirlenen genler: örneğin: up-regulated, down-regulated ve WGCNA hub genleri.	Biyolojik olarak anlamlı gen listesinin sınıflandırma başarısı.
Setup-2	Bir veya birden fazla özellik seçimi/çıkarımı yöntemi ile oluşturulan pipeline.	İstatistiksel/algoritmik özellik seçiminin etkisi.

3.2. Sınıflandırma Modelleri ve Değerlendirme

- En az üç farklı eğitici makine öğrenmesi yöntemi kullanılmalıdır.
- Her model, üç farklı setup üzerinde çalıştırılmalı ve sonuçlar karşılaştırılmalıdır.
- 5-Fold Cross Validation uygulanmalıdır.
- Accuracy, precision, recall ve F1-measure metrikleri karşılaştırmalı bir tablo halinde verilmelidir.
- Confusion matrix ile örneklerin doğru/yanlış sınıflandırılma sayıları gösterilmelidir.
- ROC curve grafikleri oluşturulmalı ve modeller arası performans farkları yorumlanmalıdır.

4. Rapor İçeriği

- Veri setinin adı, kaynağı, hastalık türü, örnek sayısı, sınıf dağılımı ve seçilen sınıflar açıkça belirtilmelidir.
- Ön işleme ve normalizasyon adımlarıyla ilgili grafikler eklenmelidir.
- DGE, survival, Cox, WGCNA ve GO enrichment analizleri için elde edilen grafikler ve yorumlar verilmelidir.
- Makine öğrenmesi setup'ları, kullanılan modeller ve değerlendirme metrikleri sonuçları şekilleri eklenmelidir.
- Rapor PDF formatında teslim edilmelidir.

5. Sunum

- Her grup, proje kapsamında yaptığı analizleri özetleyen bir sunum hazırlamalıdır.
- Sunum süresi 15 dakikadır.
- Sunumda veri seti, kullanılan yöntemler, temel sonuçlar, grafikler ve yorumlar yer almalıdır.

6. Genel Notlar

- Proje istenilen programlama dili ile gerçekleştirilebilir.
- Gen analizleri için derste gösterilen R paketlerini kullanmanız uygulamayı kolaylaştıracaktır.
- **Derste paylaşılan kodlar temel rehber niteliğindedir. Sadece bu kodların çıktısını teslim etmek tam puan almak için yeterli değildir; veri setinize uygun ekleme ve geliştirme yapılmanız beklenmektedir.**
- Analizlerde kullanılan eşikler, model seçimleri ve yorumlar raporda gerekçelendirilmelidir.

7. Formlar ve Teslim Tarihleri

Veriseti Bildirim Formu	https://forms.gle/b3vHUEiKVkp6GrAU9
Form Son Giriş Tarihi	18 Mayıs 2026, 23:59
Seçilen Veri Setlerini Kontrol Etme Linki	https://docs.google.com/spreadsheets/d/1CjnFQ2M7s-O55BKrQSPBuEy_rTRuQEFlmZlxJHOgEvul/edit?usp=sharing
Proje Son Teslim Tarihi	04 Haziran 2026, 23:59
Teslim Yeri	online.yildiz.edu.tr

Uyarı: Belirtilen tarihe kadar veri seti formunu doldurmayan öğrenciler/gruplar proje değerlendirmesine alınmayacaktır. Aynı veri setini seçen gruplar uyarılacak ve veri seti değişikliği yapmaları istenecektir.