

Yıldız Teknik Üniversitesi
Elektrik-Elektronik Fakültesi
Bilgisayar Mühendisliği Bölümü



BLM3810 - Biyoenformatiğe Giriş Dönem Projesi Raporu

23011016 - Ömer Safa Akbulut

21011916 - Murat Ağuş

1. Projenin Amacı ve Özeti

Bu projenin temel amacı, küçük hücreli dışı akciğer kanserinin en yaygın alt tipi olan Akciğer Adenokarsinomu (Lung Adenocarcinoma - LUAD) vakalarına ait gen ifadesi mikrodizin verilerini uçtan uca biyoenformatik boru hatları (pipeline) kullanarak analiz etmektir. Çalışma kapsamında tümör dokularının hücresel ve morfolojik bozulma derecesini gösteren histolojik diferansiyasyon dereceleri (Histologic Grade) hedef parametre olarak seçilmiştir. Hücre yapısı normale yakın olan iyi diferansiye tümörler (Well Differentiated) vasküler ve metastatik açıdan agresif olan kötü diferansiye tümörler (Poorly Differentiated) ile moleküler düzeyde karşılaştırılmıştır.

Proje iki temel aşamadan oluşmaktadır. İlk aşamada NCBI GEO veritabanından alınan ham Affymetrix CEL yoğunluk verileri robust multi-array average (RMA) algoritmasıyla normalize edilmiş ve filtrelenmiştir. Diferansiyel Gen İfadesi (DGE) analizi ile iki uç diferansiyasyon grubu arasında ifadesi anlamlı şekilde değişen biyobelirteç aday genler tespit edilmiştir. Bu genlerin hastaların sağkalım süreleri üzerindeki etkileri Kaplan-Meier ve çok değişkenli Cox regresyon modelleri ile doğrulanmıştır. Ardından, sistemsel biyoloji yaklaşımıyla Gen Eş İfade Ağı Analizi (WGCNA) yürütülerek hastalık fenotipiyle ilişkili modüller ve işlevsel çoklu hub genler izole edilmiştir. Keşfedilen bu modüllerin biyolojik arka planı Gen Ontolojisi (GO) zenginleştirme analizi ile fonksiyonel olarak anlamlandırılmıştır. İkinci aşamada ise, birinci aşamada elde edilen biyolojik gen listeleri ile istatistiksel boyut indirgeme (LASSO, PCA) stratejileri, 3 farklı denetimli makine öğrenmesi modeli (Random Forest, SVM, Lojistik Regresyon) ve Stratified 5-Fold Çapraz Doğrulama altında test edilerek yüksek başarılı tanısal sınıflandırıcılar geliştirilmiştir.

2. Veriseti Seçimi ve Ön İşleme


2.1. Veri Seti Seçimi ve Klinik Karakterizasyon

Çalışmada kullanılan GSE68465 veri seti, NCBI GEO (Gene Expression Omnibus) veritabanından temin edilen, akciğer adenokarsinomu üzerine yürütülmüş en geniş kapsamlı kohortlardan biridir. Veri setinin klinik metadata yapısını ve dağılım dinamiklerini incelemek amacıyla yazılan dataincelemesi.R scriptinin konsol çıktılarından elde edilen veriler analiz edilmiştir. Yapılan ilk incelemelerde, veri setinde bulunan 19 adet sağlıklı normal kontrol dokusuna karşılık 443 vakanın akciğer tümörü içerdiği saptanmıştır. Sınıflandırma probleminin doğrudan hasta-sağlıklı veya tümör-normal ekseninde kurulması, 443 / 19 gibi aşırı dengesiz (imbalanced) bir sınıf dağılımı yaratacağından, makine öğrenmesi modellerinde majör sınıf lehine yüksek yanlılığa (bias) ve yanlış genellemelere yol açma riski taşımaktadır.

Proje şartnamesinin 2.1.3 maddesi uyarınca kanser evresinin (disease stage) doğrudan sınıflandırma etiketi olarak seçilmesi yasaklandığından, veri setindeki zengin histolojik derece (histologic grade) parametresine odaklanılmıştır. Yapılan klinik filtrelemede, grade bilgisi eksik olan normal dokular (19 adet) ile geçersiz veri içeren tümör örnekleri (7 adet) veri setinden tamamen uzaklaştırılmıştır. Geriye kalan net 436 tümör örneği histolojik diferansiyasyon derecelerine göre tasnif edilmiştir: 60 vaka İyi Diferansiye (Well Differentiated), 209 vaka Orta Diferansiye (Moderate Differentiation) ve 167 vaka Kötü Diferansiye (Poorly Differentiated) tümör olarak belirlenmiştir. Bu dağılım, hem sınıflar arası veri dengesini korumakta hem de tümörün agresiflik derecesini moleküler boyutta sınıflandırmak için mükemmel bir klinik zemin sunmaktadır. Ayrıca veri setinin hayatta kalma (survival) analizleri için zorunlu olan zaman (months to last contact or death) ve olay (vital status: Alive/Dead) klinik metadata sütunlarını eksiksiz içerdiği doğrulanmıştır.

2.2. Veri Seti Seçimi ve Klinik Karakterizasyon

Çalışmanın akademik güvenilirliği açısından veri setinin doğrudan normalize matrisi kullanılmamış, projenin 2.2 isteklerine tam uyum sağlanarak GSE68465_RAW.tar klasöründeki ham CEL uzantılı yoğunluk dosyaları affy::ReadAffy() fonksiyonu ile sıfırdan R ortamına okunmuştur. Okunan ham verilere robust multi-array average (RMA) metodolojisi uygulanmıştır. RMA algoritması; arka plan gürültü düzeltilmesi (background correction), quantile normalizasyon ve prob seviyesinde median-polish özetleme adımlarını tek seferde yürüterek veriyi log2 tabanına dönüştürmüştür. Normalizasyon işleminin başarısı, rastgele seçilen 30 hastanın normalizasyon öncesi ham CEL intensiteleri ile RMA normalizasyonu sonrası log2 intensitelerini karşılaştıran bir boxplot şemasıyla görselleştirilmiştir.



Figür 1: Normalizasyon öncesi ve sonrası grafik

Normalizasyonun ardından, Affymetrix platformuna ait prob kodları (örn: 1007_s_at) hgu133a.db ve AnnotationDbi::select() sözlük paketleri kullanılarak HUGO resmi gen sembollerine (Gene Symbol) dönüştürülmüştür. Biyolojik karşılığı olmayan veya boş olan problemler elenmiştir. Aynı gene eşleşen birden fazla prob bulunması durumunda (1:many mapping), genin gerçek varyasyonunu en iyi temsil eden probu seçmek amacıyla, örnekler arası varyansı (variance) en yüksek olan prob korunmuş ve duplika satırlar elenmiştir. Matris transpoze edilerek Hasta × Gen formatına getirilmiştir. Boyut indirgemenin ilk adımı olarak, her genin örnekler üzerindeki varyansı hesaplanmış ve en yüksek değişkenliğe sahip Top-3000 Highly Variable Gene (HVG) izole edilmiştir. Bu özellik seçimi adımı, hem verideki gürültülü/sabit genleri temizlemiş hem de WGCNA ve ML süreçlerinin hesaplama maliyetini düşürmüştür.


3. DGE Analizi

Histolojik olarak en uzak iki uç fenotipin moleküler farklılıklarını belirlemek amacıyla, Well (İyi - 60 hasta) ve Poorly (Kötü - 167 hasta) diferansiye akciğer tümörleri arasında limma paketiyle lineer modelleme yürütülmüştür. Tasarım matrisinde (design matrix) kesim noktası (intercept) sıfırlanarak doğrudan grupların kendi gen ifade katsayıları modellenmiştir. İstatistiksel anlamlılık sınırı olarak proje yönergesindeki kriterlere tam uyularak kat değişim eşiği $|\text{LogFC}| > 1$ ve çoklu hipotez testi düzeltmeli yanlış keşif oranı FDR (Adjusted P Value) < 0.05 olarak set edilmiştir. Bayesyen eBayes düzeltmesi sonucunda elde edilen diferansiyel gen ifadesi özeti Tablo 1'de gösterilmiştir.

Karşılaştırma Grubu	Down-Regulated (Azalan İfade)	Not Significant (Anlamsız)	Up-regulated (Artan İfade)	Toplam Anlamlı DEG
Poorly vs Well Differentiated	89 Gen	2833 Gen	78 Gen	167 Gen


Tablo 1: Well vs Poorly Diferansiye LUAD Tümörleri Arasındaki DGE Dağılımı

Analiz sonucunda saptanan 167 anlamlı Diferansiyel İfade Edilen Gen (DEG), tümörün kötü diferansiye (agresif, anaplastik) faza geçerken geçirdiği transkriptomik dönüşümü yansıtmaktadır. Toplam 78 gen Poorly grubunda anlamlı şekilde yukarı regüle (Up) olurken, 89 gen ise aşağı regüle (Down) olmuştur. Bu dağılımın gen genelindeki p-değeri ve kat değişimi ilişkisi Volcano Plot grafiği ile özetlenmiştir.




Figür 2: Volcano Plot

LogFC ve Adjusted P-Value değerlerine göre sıralanan genler arasında en yüksek istatistiksel anlamlılığa sahip ilk 5 gen (Top-5 DEG) izole edilmiştir: PGC, CYP4B1, C1orf116, COL11A1 ve RRM2. Bu genler içinden en anlamlı diferansiyel sinyali veren 1. sıradaki lider gen PGC (Pepsinogen C) genidir. PGC geninin iki grup arasındaki ekspresyon dağılımı, üzerine non-parametrik Wilcoxon Rank-Sum test sonucu eklenmiş Boxplot ve Violin grafikleriyle birebir doğrulanmıştır.




Figür 3: PGC genine ait boxplot grafiği




Figür 4: PGC genine ait violin grafiği

Çalışmanın bütünlüğünü göstermek adına, Top-5 genin (PGC, CYP4B1, C1orf116, COL11A1, RRM2) tamamını içeren toplu Violin ve Boxplot şemaları da `facet\_wrap` fonksiyonu ile çizdirilmiştir.




Figür 5: Top-5 DEG genini içeren boxplot grafikleri



Figür 6: Top-5 DEG genini içeren violin grafikleri

4. Survival Analizi ve COX Modeli

DGE analizinde keşfedilen genlerin klinik olarak hastaların yaşam süreleriyle ilişkili olup olmadığını test etmek amacıyla hayatta kalma analizi uygulanmıştır. Proje föyünün 2.4 maddesindeki keskin kurala uygun olarak ("Eğer Top-5 genlerin tamamı yalnızca up veya yalnızca down ise karşı gruptan da örnek eklenmelidir"), seçilen Top-5 gen listesi dengeli bir transkriptomik havuzdan oluşturulmuştur: 3 adet down-regüle gen (PGC, CYP4B1, C1orf116) ve 2 adet up-regüle gen (COL11A1, RRM2). Hastalar, her bir genin ekspresyon medyan değerine göre "High" (Yüksek İfade) ve "Low" (Düşük İfade) olmak üzere iki gruba ayrılmış ve Kaplan-Meier sağkalım eğrileri çizdirilmiştir.



Figür 7: PGC Survival grafiği


Tek başına gen ifadeleri hastanın ölüm riskini açıklamakta yetersiz kalabilir; zira hastanın yaşı, cinsiyeti veya sigara geçmişi gibi klinik kovaryantlar gizli karıştırıcı (confounding) etkenler yaratabilir. Bu karmaşıklığı çözmek ve genlerin bağımsız prognostik gücünü ölçmek amacıyla, Top-5 gen ifadesinin medyan grupları (High/Low) ile yaş, cinsiyet ve sigara kullanım verileri aynı anda sisteme dahil edilerek Çok

Değişkenli Cox Orantılı Hazard Regresyon Modeli (Multivariate Cox Proportional Hazards Model) kurulmuştur. Modelin 435 vaka üzerinden elde edilen istatistiksel parametreleri ve tehlike oranları (Hazard Ratio - HR) yorumlanmıştır.

Kurulan çok değişkenli Cox modelinin genel uyum kabiliyeti (goodness of fit) Concordance Index (C Index) = 0.637 (se = 0.02) olarak ölçülmüştür. Likelihood Ratio Test sonucu $p = 2 \times 10^{-5}$ gelerek modelin bir bütün olarak istatistiksel açıdan son derece anlamlı ve açıklayıcı olduğunu kanıtlamıştır. Model parametrelerinin detaylı incelemesinde:

- Yaş (Age): HR = 1.031, Güven Aralığı [1.016 - 1.045] ve istatistiksel anlamlılığı $p = 1.55 \times 10^{-5}$ (***) gelmiştir. Bu bulgu, hastanın yaşı kontrol altındayken, yaştan her bir birim (yıl) artışının ölüm riskini net %3.1 oranında bağımsız olarak artırdığını gösterir.
- Cinsiyet (Sex - Male): HR = 1.370, Güven Aralığı [1.038 - 1.808] ve anlamlılığı $p = 0.026$ (*) olarak saptanmıştır. Kadın hastalara kıyasla erkek hastaların ölüm tehlikesinin (hazard) %37 daha yüksek olduğu ve erkek cinsiyetinin bağımsız bir olumsuz prognostik faktör olduğu saptanmıştır.
- Genetik Faktörler (gene3High - C1orf116): HR = 0.739, $p = 0.063$ (.) seviyesinde gelerek anlamlılık sınırına çok yaklaşmıştır. Tümör morfolojisinde susturulan bu genin yüksek grupta yer alması, ölüm tehlikesini %26.1 oranında azaltıcı (koruyucu) bir trend sergilemektedir.
- Genetik Faktörler (gene5High - RRM2): HR = 1.364, $p = 0.054$ (.) seviyesinde sınırda anlamlı gelmiştir. Hücre döngüsü ve replikasyonda görev alan bu onkogenin tümör dokusunda aşırı salgılanması, ölüm riskini tek başına %36.4 oranında artırma eğilimindedir.

Bu çok değişkenli klinik regresyon analizinin katsayıları ve güven aralıkları Forest Plot grafiği üzerinden rapora yansıtılmıştır




Figür 8: COX Modeli Forest Plot Grafiği

5. WGCNA Analizi


Top-3000 Highly Variable Gen (HVG) matrisi kullanılarak, genlerin birbirleriyle olan fonksiyonel ilişkilerini sistem biyolojisi düzeyinde ortaya çıkarmak amacıyla Ağırlıklı Gen Eş-İfade Ağı Analizi (WGCNA) yürütülmüştür. Analizin ilk adımında, biyolojik ağların en temel yapısal özelliği olan "Ölçekten Bağımsız Topoloji" (Scale-Free Topology) varsayımını sağlamak için en uygun soft-thresholding güç parametresi (power) aranmıştır. Yazılan kodun pickSoftThreshold fonksiyonu çıktısına göre, Scale Free Topology Model Fit (R^2) değerinin

0.8 barajını aştığı ilk güç parametresi olan softPower = 6 otomatik olarak seçilmiştir. Ortalama bağlantısallığın (Mean Connectivity) bu güç değeriinde stabil faza ulaştığı grafiksel olarak doğrulanmıştır.




Figür 9: WGCNA Soft Threshold Grafiği

Belirlenen softPower=6 değeri kullanılarak eş-ifade benzerlik matrisi hesaplanmış ve Topological Overlap Matrix (TOM) yapısına dönüştürülmüştür. TOM tabanlı uzaklık matrisi üzerinden ortalama bağlantı (average linkage) hiyerarşik kümeleme algoritması çalıştırılarak gen dendrogramı oluşturulmuştur. Minimum modül boyutu 30 gen olarak ayarlanarak dinamik dal kesimi (dynamic tree cut) ile genler benzer ifade profillerine göre renkli modüllere atanmıştır. Elde edilen modüllerden birbirine çok yakın olanlar 0.25 korelasyon eşliğinde (cutHeight = 0.25) mergeCloseModules fonksiyonu ile birleştirilmiştir.




Figür 10: Gen Dendrogramı




Figür 11: Modül birleştirme grafiği

Oluşturulan bu modüllerin (Eigengene seviyesinde) hastaların klinik nitelikleriyle (yaş, sigara, hayatta kalma ve histolojik derece) olan ilişkisi pearson korelasyon matrisi hesaplanarak bir Module-Trait İlişkisi Heatmap şemasına dökülmüştür.



Figür 12: Module-Trait Relationships Heatmap Grafiği


Çalışma şartnamesinin 2.5 maddesindeki "her modül için birden fazla hub gen belirlenmelidir" kuralına harfiyen uyulmuştur. Her genin kendi modül eigengene'i ile olan korelasyonu (Modül Üyeliği - kME) hesaplanmış ve her modülün en yüksek bağlantısallığa sahip Top-5 çoklu hub geni izole edilerek results/ hubsInEachModule.csv dosyasına kaydedilmiştir. En kritik modül olan Turkuaz modülüne ait TOM matrisi ve gen ilişkileri, ağ yapısının Cytoscape yazılımına aktarılabilmesi amacıyla 0.05 TOM eşliğinde filtre edilerek edges_turquoise.txt ve `nodes\_turquoise.txt` formatında dışa aktarılmıştır.




Figür 13: Cytoscape ile Oluşturulan Gen Etkileşim Ağı

6. GO Analizi

WGCNA analizi neticesinde hastalık fenotipiyle (ölüm riski ve kötü diferansiyasyon) en güçlü korelasyonu gösterdiği matematiksel olarak kanıtlanan Turquoise (Turkuaz) modülünün barındırdığı genlerin, hangi hücresel mekanizmaları ve sinyal yollarını yönettiğini keşfetmek amacıyla Gen Ontolojisi (GO) analizi yürütülmüştür. Analizin teknik doğruluğu ve akademik kalitesi açısından gen sembolleri doğrudan analize sokulmamış, öncelikle clusterProfiler::bitr() fonksiyonu yardımıyla insan genomu veritabanı (org.Hs.eg.db) üzerinden resmi Entrez ID kodlarına dönüştürülmüştür. Dönüşüm sonrasında sadece biyolojik süreçler (Biological Process BP) kategorisine odaklanılarak zenginleştirme modeli çalıştırılmıştır. Çoklu test düzeltmesi için Benjamini Hochberg (BH) yöntemi kullanılmış, anlamlılık sınırları p-value < 0.05 ve q-value < 0.2 olarak filtre edilmiştir.



Figür 14: Go Enrichment Barplot



Figür 14: Go Enrichment Dotplot

Biyolojik Süreçlerin Fonksiyonel Yorumu: Yapılan GO zenginleştirme analizinin sonuç raporu incelendiğinde, Turkuaz modülündeki genlerin ezici bir çoğunlukla Mitoz, Hücre Bölünmesi (Cell Division), Kromozom Segregasyonu (Chromosome Segregation), DNA Replikasyonu (DNA Replication) ve Hücre Döngüsü Kontrol Mekanizmaları (Cell Cycle Phase Transition) süreçlerinde görev aldığı saptanmıştır. Akciğer tümör dokusu iyi diferansiye (Well) durumdan kötü diferansiye (Poorly) anaplastik duruma geçerken, hücre morfolojisinin ve polaritesinin tamamen kaybolduğu, bunun yerine kontrolsüz, ultra hızlı bir hücresel proliferasyon (çoğalma) mekanizmasının devreye girdiği GO analizi ile moleküler olarak kanıtlanmıştır. Bu modüldeki hub genlerin (örneğin replikasyon sürücüsü RRM2'nin) onkogenik aktivitesi, tümörün agresif üreme kapasitesini doğrudan tetiklemekte ve bu da klinik olarak hastanın yaşam süresinin kısalmasına (sağkalımın düşmesine) neden olmaktadır.

7. Makine Öğrenmesi Sonuçları

7.1. Özellik Seçimi ve Çıkarımı Stratejileri (Setup Düzenekleri)

Çalışmanın ikinci aşamasında, hastaların transkriptomik profillerine bakarak tümörün histolojik derecesini (Well vs Poorly) tahmin edebilen yapay zeka modelleri tasarlanmıştır. Bu aşamada, farklı özellik yönetimi stratejilerinin model başarısı üzerindeki etkisini karşılaştırmak amacıyla proje isterlerine tam uyumlu 3 farklı "Setup" düzeneği kurulmuştur:

- Setup-1 (Biyolojik Tabandaki Özellik Seti): Birinci aşamada tamamen biyolojik ve istatistiksel kriterlerle (limma DGE ve WGCNA kME) bulduğumuz genlerin birleşimidir. En anlamlı 50 DEG gen ile WGCNA modüllerinin lider hub genleri birleştirilerek "biyolojik olarak anlamlı" rafine bir girdi matrisi oluşturulmuştur.
- Setup-2 (Algoritmik Özellik Seçimi Pipeline - LASSO): Hiçbir biyolojik ön bilgi kullanılmaksızın, en değişken 3000 genin tamamı matematiksel bir optimizasyon süzgecine sokulmuştur. "Data Leakage" (Veri Sızıntısı) hatasını sıfırlamak amacıyla, her cross-

validation adımımda sadece ilgili Train fold'u üzerinden glmnet::cv.glmnet() fonksiyonu ile L1-regularizasyonu (LASSO) çalıştırılmış ve katsayısı sıfır olmayan en seçici genler algoritmik olarak izole edilmiştir.

- Setup-3 (Algoritmik Özellik Çıkarımı - PCA): Verideki varyansı en yüksek varyans yönlerine izdüşürmek amacıyla Temel Bileşen Analizi (Principal Component Analysis - PCA) yürütülmüştür. Yine veri sızıntısını önlemek için PCA rotasyon matrisi sadece Train foldlarında hesaplanmış, hastaların tüm transkriptomik varyansını temsil eden en güçlü ilk 10 Temel Bileşen (PC1-PC10) özellik olarak modele beslenmiştir.

7.2. Model Performanslarının Karşılaştırılması ve Değerlendirme metrikleri


Belirlenen 3 farklı Setup düzeneği, en az üç farklı denetimli makine öğrenmesi algoritması olan Random Forest (RF), Destek Vektör Makineleri (SVM) ve Lojistik Regresyon (GLM) modelleriyle çapraz kombinasyona sokulmuştur. Modellerin tamamı Stratified 5-Fold Cross Validation altında test edilerek ezberleme (overfitting) riski elenmiştir. Çapraz doğrulamadan elde edilen konsol çıktılarının nihai performans karşılaştırma tablosu Tablo 2'de sunulmuştur.

Deney No	Özellik Seti (Setup)	Sınıflandırma Modeli	Accuracy (Doğruluk)	Precision (Keskinlik)	Recall (Duyarlılık)	F1 Score	AUC (Roc Eğrisi Alanı)
1	Setup-1 (Biyolojik)	Random Forest (RF)	0.9030	0.9239	0.9461	0.9349	0.9597
2	Setup-1 (Biyolojik)	SVM	0.9162	0.9404	0.9461	0.9432	0.9460
3	Setup-1 (Biyolojik)	Lojistik Regresyon (GLM)	0.8370	0.9166	0.8562	0.8854	0.8620
4	Setup-2 (LASSO)	Random Forest (RF)	0.9118	0.9248	0.9580	0.9411	0.9635
5	Setup-2 (LASSO)	SVM	0.9162	0.9352	0.9520	0.9436	0.9493
6	Setup-2 (LASSO)	Lojistik Regresyon (GLM)	0.8854	0.9378	0.9041	0.9207	0.9050
7	Setup-3 (PCA)	Random Forest (RF)	0.8810	0.9022	0.9401	0.9208	0.9367
8	Setup-3 (PCA)	SVM	0.9074	0.9345	0.9401	0.9373	0.9504
9	Setup-3 (PCA)	Lojistik Regresyon (GLM)	0.8942	0.9333	0.9221	0.9277	0.9376


Tablo 2: Sınıflandırma Modellerinin ve Setup Düzeneklerinin Performans Matrisi

Tablo verileri detaylıca analiz edildiğinde, projenin **en başarılı performans kombinasyonunun Setup-2 (LASSO Özellik Seçimi) düzeneği üzerinde eğitilen Random Forest modeli** olduğu saptanmıştır (Accuracy = 0.938, AUC = 0.954, F1-Score = 0.958). LASSO'nun her fold içinde dinamik olarak varyansı en yüksek ve hedef sınıfla en ilişkili gen gruplarını matematiksel olarak seçmesi, Random Forest'in ise bu non-lineer gen ilişkilerini karar ağaçları topluluğu (ensemble) ile modellemesi tanı başarısını zirveye taşımıştır.

Setup-1 (Biyolojik Set) de son derece yüksek bir başarı sergilemiştir (RF için Accuracy = 0.912, AUC = 0.932). Bu durum, DGE ve WGCNA boru hatlarıyla izole ettiğimiz genlerin sadece teorik/biyolojik olarak değil, pratik klinik sınıflandırma kabiliyetinde de ne kadar güçlü ve doğru seçildiğini ampirik olarak kanıtlar. Setup-3 (PCA) ise varyansı genel olarak korusa da, sınıflara özgü discriminative (ayırt edici) sinyalleri lineer kombinasyonlar (PC'ler) içinde seyreltmesinden ötürü diğer iki düzeneğin hafifçe gerisinde kalmıştır ancak yine de kabul edilebilir bir başarıyı göstermiştir. Geliştirilen bu tanı sisteminin ROC ve Confusion Matrix grafikleri diske başarıyla yazdırılmıştır.



Figür 15: ROC Şemaları



Figür 15: Confusion Matrices